

Orquestación de agentes de lenguaje para el desarrollo de software

Una política de descomposición adaptativa con verificación basada en evidencia

Francisco Clarke
LU 120547

Departamento de Ciencias e Ingeniería de la Computación
Universidad Nacional del Sur

Directora: Dra. Ana Gabriela Maguitman
Codirector: Dr. Federico Martín Schmidt

2026

El problema

Un agente de lenguaje puede resolver una tarea de programación acotada. Un objetivo real de software no es una tarea acotada.

El problema

Un agente de lenguaje puede resolver una tarea de programación acotada. Un objetivo real de software no es una tarea acotada.

La salida natural es **descomponer**. Y ahí aparece la tensión:

Dividir de menos

- El agente satura su contexto.
- No hay puntos de verificación intermedios.
- Un fallo invalida todo el trabajo.

Dividir de más

- Aparecen contratos entre unidades.
- Crece el costo de integración.
- Los conflictos serializan el trabajo.

El problema

Un agente de lenguaje puede resolver una tarea de programación acotada. Un objetivo real de software no es una tarea acotada.

La salida natural es **descomponer**. Y ahí aparece la tensión:

Dividir de menos

- El agente satura su contexto.
- No hay puntos de verificación intermedios.
- Un fallo invalida todo el trabajo.

Dividir de más

- Aparecen contratos entre unidades.
- Crece el costo de integración.
- Los conflictos serializan el trabajo.

La paradoja de la granularidad: el óptimo no es un extremo, y no es el mismo para todas las tareas.

Preguntas de investigación

- PI-1 ¿Puede construirse un orquestador que descomponga un objetivo en un DAG, lo ejecute aislado y concurrente, y llegue a una entrega **verificada**?
- PI-2 ¿Puede una política decidir **si** dividir una unidad y **seleccionar** entre los cortes que el planificador propone, hasta llegar a hojas implementables por un agente?
- PI-3 ¿Qué modos de falla aparecen cuando la granularidad no coincide con la forma real del trabajo?

Preguntas de investigación

- PI-1 ¿Puede construirse un orquestador que descomponga un objetivo en un DAG, lo ejecute aislado y concurrente, y llegue a una entrega **verificada**?
- PI-2 ¿Puede una política decidir **si** dividir una unidad y **seleccionar** entre los cortes que el planificador propone, hasta llegar a hojas implementables por un agente?
- PI-3 ¿Qué modos de falla aparecen cuando la granularidad no coincide con la forma real del trabajo?

PI-2 dice *seleccionar*, no *encontrar*: que la política no puede inventar el corte es un resultado de esta tesis, no un supuesto.

Estudio **exploratorio** de viabilidad y modos de falla.
No busca —ni podría alcanzar— significancia estadística.

La política de descomposición adaptativa

Cada unidad recibe cuatro señales normalizadas en $[0, 10]$:

$$C_{task} = w_1 S_r + w_2 I_i + w_3 V_s + w_4 T_m$$

Símbolo	Dimensión	Peso
S_r	Radio de alcance (archivos y módulos afectados)	0,30
I_i	Impacto sobre interfaces exportadas	0,25
V_s	Superficie de validación	0,25
T_m	Masa de contexto en tokens	0,20

Una unidad se mantiene como hoja si $C_{task} \leq 3,5$.

La política de descomposición adaptativa

Cada unidad recibe cuatro señales normalizadas en $[0, 10]$:

$$C_{task} = w_1 S_r + w_2 I_i + w_3 V_s + w_4 T_m$$

Símbolo	Dimensión	Peso
S_r	Radio de alcance (archivos y módulos afectados)	0,30
I_i	Impacto sobre interfaces exportadas	0,25
V_s	Superficie de validación	0,25
T_m	Masa de contexto en tokens	0,20

Una unidad se mantiene como hoja si $C_{task} \leq 3,5$.

Validación híbrida: el modelo *propone* las señales; un validador determinista las *acota* contra la superficie real del repositorio. El origen de cada señal queda registrado como *llm*, *clamped* o *derived*.

Dónde está la frontera

La política decide **si** dividir.

Solo el Arquitecto puede decir **cómo**.

Dónde está la frontera

La política decide **si** dividir.

Solo el Arquitecto puede decir **cómo**.

Esto no es una decisión de escritorio: es un **resultado negativo** obtenido de un run real.

- Una versión previa fabricaba sub-unidades particionando rutas de forma mecánica cuando el Arquitecto no proponía ninguna.
- En un run canónico los tres agentes terminaron con código de salida 0, y **los tres candidatos fueron rechazados por violar su propio contrato de alcance**.
- Causa: implementar una porción de la API también necesita el tipo del dominio del que depende. Una partición de rutas no es una unidad de trabajo coherente.

Dónde está la frontera

La política decide **si** dividir.

Solo el Arquitecto puede decir **cómo**.

Esto no es una decisión de escritorio: es un **resultado negativo** obtenido de un run real.

- Una versión previa fabricaba sub-unidades particionando rutas de forma mecánica cuando el Arquitecto no proponía ninguna.
- En un run canónico los tres agentes terminaron con código de salida 0, y **los tres candidatos fueron rechazados por violar su propio contrato de alcance**.
- Causa: implementar una porción de la API también necesita el tipo del dominio del que depende. Una partición de rutas no es una unidad de trabajo coherente.

Corrección: se retiró la síntesis mecánica. Sin sub-unidades propuestas se conserva la hoja cohesiva y se registra `resplit_declined`.

Recorrido de un run

1. **Grounding** — se indexa el repositorio objetivo; el plan cita rutas que existen.
2. **Planificación** — el planificador emite unidades semánticas y señales de complejidad.
3. **Política adaptativa** — C_{task} reforma el árbol; la decisión se persiste como evento.
4. **Compilación** — grafo con cuatro relaciones tipadas: pertenencia, artefactos, costuras y restricciones de conflicto.
5. **Ejecución** — cada hoja corre en un worktree de Git aislado, con *lease* y *fencing*.
6. **Validación** — matriz de evidencias sobre el commit exacto.
7. **Integración** — bottom-up, con reparación semántica.
8. **Entrega** — manifiesto y receipt sobre el árbol validado.

Dos invariantes que sostienen todo

1. **git diff es la única fuente de verdad.**

El agente no commitea. El orquestador inspecciona el árbol y commitea el diff exacto. Lo que el agente *dice* que hizo no entra en la evidencia.

2. **El alcance es un contrato, no una sugerencia.**

Cada nodo declara las rutas que puede modificar. Un archivo fuera de contrato invalida el candidato.

Dos invariantes que sostienen todo

1. `git diff` es la única fuente de verdad.

El agente no commitea. El orquestador inspecciona el árbol y commitea el diff exacto. Lo que el agente *dice* que hizo no entra en la evidencia.

2. El alcance es un contrato, no una sugerencia.

Cada nodo declara las rutas que puede modificar. Un archivo fuera de contrato invalida el candidato.

Este segundo invariante tuvo un costo medido: bajo alcance estricto, un archivo de prueba *nuevo* que el planificador no anticipó hacía fallar trabajo correcto. La corrección fue **creación acotada**: un nodo puede crear archivos bajo los directorios que ya posee —roots derivados por el compilador, nunca pedidos por el modelo—, pero editar un archivo preexistente no declarado sigue fuera de alcance.

Cómo se evaluó

Caso canónico: repositorio objetivo externo, commit base congelado, objetivo que cruza dominio, API, superficie web y pruebas. Codex CLI (gpt-5.5) en planificación y ejecución.

Estudio comparativo: 2 tareas $\times$ 3 condiciones $\times$ 2 repeticiones. Las dos tareas caen **en lados opuestos del umbral**: si ambas fueran complejas, la condición de hoja única fallaría por construcción y la política adaptativa parecería superior por una razón trivial.

Cómo se evaluó

Caso canónico: repositorio objetivo externo, commit base congelado, objetivo que cruza dominio, API, superficie web y pruebas. Codex CLI (gpt-5.5) en planificación y ejecución.

Estudio comparativo: 2 tareas $\times$ 3 condiciones $\times$ 2 repeticiones. Las dos tareas caen **en lados opuestos del umbral**: si ambas fueran complejas, la condición de hoja única fallaría por construcción y la política adaptativa parecería superior por una razón trivial.

Todo se fijó **antes** de observar resultados: tareas, orden, métricas, hipótesis, su falsador y una regla de inconclusión.

Las tablas y figuras se derivan automáticamente del journal de eventos. Ninguna cifra se transcribe a mano.

El resultado: la hipótesis quedó falsada

Tarea	Cond.	Entregas	Reloj (s)	Tokens
T1 multi-capa	A <i>no dividir</i>	2/2	259, 357	22k, 25k
T1 multi-capa	B división fina	1/2	942, 1209	112k, 101k
T1 multi-capa	C adaptativa	1/2	810, 1109	104k, 96k
T2 acotada	A	2/2	282, 291	30k, 28k
T2 acotada	B	2/2	362, 393	52k, 28k
T2 acotada	C	2/2	344, 351	32k, 26k

El resultado: la hipótesis quedó falsada

Tarea	Cond.	Entregas	Reloj (s)	Tokens
T1 multi-capa	A <i>no dividir</i>	2/2	259, 357	22k, 25k
T1 multi-capa	B división fina	1/2	942, 1209	112k, 101k
T1 multi-capa	C adaptativa	1/2	810, 1109	104k, 96k
T2 acotada	A	2/2	282, 291	30k, 28k
T2 acotada	B	2/2	362, 393	52k, 28k
T2 acotada	C	2/2	344, 351	32k, 26k

En T2 la hipótesis se sostiene, y por el mecanismo previsto: las tres condiciones convergieron a *una sola unidad* —incluida la que fuerza dividir—. Sobre una tarea cohesiva, dividir no es una opción disponible.

El resultado: la hipótesis quedó falsada

Tarea	Cond.	Entregas	Reloj (s)	Tokens
T1 multi-capa	A <i>no dividir</i>	2/2	259, 357	22k, 25k
T1 multi-capa	B división fina	1/2	942, 1209	112k, 101k
T1 multi-capa	C adaptativa	1/2	810, 1109	104k, 96k
T2 acotada	A	2/2	282, 291	30k, 28k
T2 acotada	B	2/2	362, 393	52k, 28k
T2 acotada	C	2/2	344, 351	32k, 26k

En T2 la hipótesis se sostiene, y por el mecanismo previsto: las tres condiciones convergieron a *una sola unidad* —incluida la que fuerza dividir—. Sobre una tarea cohesiva, dividir no es una opción disponible.

En T1 se falsa, en la dirección más desfavorable: no descomponer entregó 2/2, con cerca de un tercio del tiempo y un cuarto de los tokens, y la *misma* superficie funcional.

Por qué tampoco autoriza la conclusión inversa

- **El repositorio es chico** —5 pruebas de base, aprox. 25k tokens por run—. La descomposición se hipotetiza útil cuando un agente *satura su contexto*. Eso no pasó ni cerca: el experimento no puso a prueba su hipótesis en el régimen que le es favorable.
- **Dos celdas discrepan entre repeticiones** → la varianza del planificador domina sobre el efecto de la condición.
- **Los fallos no fueron de granularidad**: un timeout de agente y una validación cuya reparación salió de alcance.

Por qué tampoco autoriza la conclusión inversa

- **El repositorio es chico** —5 pruebas de base, aprox. 25k tokens por run—. La descomposición se hipotetiza útil cuando un agente *satura su contexto*. Eso no pasó ni cerca: el experimento no puso a prueba su hipótesis en el régimen que le es favorable.
- **Dos celdas discrepan entre repeticiones** → la varianza del planificador domina sobre el efecto de la condición.
- **Los fallos no fueron de granularidad**: un timeout de agente y una validación cuya reparación salió de alcance.

Un defecto de medición que invalida la lectura ingenua

Los criterios de aceptación se compilan **por unidad**: descomponer multiplica las obligaciones. Las 12 celdas dieron cobertura 1,00 — pero cada condición satisfizo *su propia* vara (5 criterios en A, 14 en B y C).

Lo que este diseño permite decir

Permite

- Caracterizar viabilidad.
- Describir trade-offs observados.
- Identificar **modos de falla**.
- Reportar la variabilidad del planificador.

No permite

- Afirmar superioridad de la política.
- Reportar significancia.
- Generalizar a otros repositorios.
- Calibrar los pesos.

Lo que este diseño permite decir

Permite

- Caracterizar viabilidad.
- Describir trade-offs observados.
- Identificar **modos de falla**.
- Reportar la variabilidad del planificador.

No permite

- Afirmar superioridad de la política.
- Reportar significancia.
- Generalizar a otros repositorios.
- Calibrar los pesos.

Con $n = 2$ por celda, una muestra chica rinde en lo cualitativo.
Los modos de falla son el resultado, no un subproducto.

Segunda línea de evidencia: grafos anchos

La objeción al estudio comparativo es justa: el repositorio era chico y el agente único nunca saturó su contexto. La línea Warehouse ataca ese régimen con N módulos independientes sobre una base verificada externamente.

Segunda línea de evidencia: grafos anchos

La objeción al estudio comparativo es justa: el repositorio era chico y el agente único nunca saturó su contexto. La línea Warehouse ataca ese régimen con N módulos independientes sobre una base verificada externamente.

Resultado: no entregó. Nueve celdas de grafo ancho, tres series congeladas, cero commits candidatos. La cadena longitudinal se detuvo en **1/8**.

Segunda línea de evidencia: grafos anchos

La objeción al estudio comparativo es justa: el repositorio era chico y el agente único nunca saturó su contexto. La línea Warehouse ataca ese régimen con N módulos independientes sobre una base verificada externamente.

Resultado: no entregó. Nueve celdas de grafo ancho, tres series congeladas, cero commits candidatos. La cadena longitudinal se detuvo en **1/8**.

Cada causa terminal quedó atribuida y **ninguna es una decisión de granularidad**: dos defectos del compilador de grafos, la muerte no explicada del proceso dueño de un run, y un fallo del entorno del proveedor.

El término que decidía

Sobre el único grafo ancho grande medido, la política midió paralelismo 0,8889 y **aun así no aprobó dividir por utilidad**. Invertiendo la salida registrada, el término que ligaba era la duplicación de validación: 0,8947.

El término que decidía

Sobre el único grafo ancho grande medido, la política midió paralelismo 0,8889 y **aun así no aprobó dividir por utilidad**. Invertiendo la salida registrada, el término que ligaba era la duplicación de validación: 0,8947.

Caso	dup.	ventaja	razón
19 hijos, intenciones compartidas	0,8947	−0,2584	hoja infactible
11 hojas, intenciones compartidas	0,8500	+0,0444	bajo el mínimo
7 hojas, intenciones propias	0,3750	+0,1710	utilidad
11 hojas, intenciones propias	0,4828	+0,3275	hoja infactible

El término que decidía

Sobre el único grafo ancho grande medido, la política midió paralelismo 0,8889 y **aun así no aprobó dividir por utilidad**. Invertiendo la salida registrada, el término que ligaba era la duplicación de validación: 0,8947.

Caso	dup.	ventaja	razón
19 hijos, intenciones compartidas	0,8947	-0,2584	hoja infactible
11 hojas, intenciones compartidas	0,8500	+0,0444	bajo el mínimo
7 hojas, intenciones propias	0,3750	+0,1710	utilidad
11 hojas, intenciones propias	0,4828	+0,3275	hoja infactible

El término medía bien: lo que fallaba era el planificador adhiriendo criterios de objetivo completo a cada hoja. **Sin tocar término, fórmula ni umbral.**

La serie final que sí cuenta

V2 reemplaza las líneas históricas incompletas como evidencia positiva central.

- Target Node ESM pequeño; tareas M (multi-capas) y S (cohesiva).
- Dos repeticiones adaptativas por tarea; rehearsal excluido.
- Codex gpt-5.4-mini/medium, cero retries, build antes de cada run.
- Oráculo externo sobre el commit candidato exacto.

H-F1: 4/4 entregas + 4/4 oráculos H-F2: 4/4 topologías esperadas

La tarea M produjo raíz composite con 3 hojas en ambas repeticiones; la tarea S, una envoltura de raíz con 1 hoja ejecutable en ambas.

Conclusiones

- **Resultado final V2:** H-F1 y H-F2 pasan 4/4 en el target congelado. Las cuatro celdas fueron entregadas y verificadas por oráculo externo sobre sus commits exactos; M produjo 3 hojas y S 1 hoja en ambas repeticiones.
- Se construyó un orquestador que lleva un objetivo hasta un resultado **integrado, verificado y entregado**, con evidencia auditable de cada paso.
- La descomposición adaptativa está en la ruta productiva y su decisión queda **persistida y explicable** run por run.
- **Dos hallazgos negativos** son lo más transferible. Una política determinista puede *detectar* exceso de complejidad pero no puede *inventar el corte semántico*; y los criterios de aceptación son endógenos a la configuración comparada, así que toda métrica de éxito construida sobre ellos evalúa a cada una contra su propia vara.
- **No se afirma superioridad de la política adaptativa.** El estudio falsó su hipótesis y el documento lo reporta como tal.
- **Tampoco se afirma que la arquitectura escale.** Ninguna serie de grafo ancho entregó y la cadena longitudinal quedó en 1/8. Lo que sí quedó cerrado es la pregunta abierta sobre la política: el término que la hacía rechazar cortes anchos medía bien, y se demostró midiendo, sin mover el umbral.
- **La política sabe cuándo dividir mejor que cuándo parar.** Sobre 84 intentos de hoja preservados, ningún proxy de tamaño separa entrega de fallo, y el único fallo atribuible a la granularidad ocurrió en la hoja *más chica* del corpus.
- Los defectos que importaron no se encontraron leyendo código, sino **ejecutando runs reales** contra un repositorio de verdad.

- Calibrar los pesos de C_{task} con una muestra que lo permita; el diseño actual, deliberadamente, no lo sostiene.
- Enmiendas versionadas de alcance: convertir una violación en una propuesta de revisión del grafo en lugar de una falla terminal.
- Ampliar el estudio a repositorios de dominios y tamaños distintos.
- Reducir la dependencia de la variabilidad del proveedor en planificación.

¿Preguntas?